

CPBL_CrawlerBPN

(使用2015-2022年 統一隊與兄弟隊比賽數據)

說明

研究目標：

1. 利用投手與打擊數據
2. 預測比賽勝負結果

問題：

1. 哪些數據最影響勝負？
2. 傳統機器學習與神經網路誰比較好？
3. 能否建立實際預測模型？

方法:


利用 PyTorch 實作倒傳遞神經網路（Backpropagation Neural Network, BPN），建立深度學習模型進行比賽勝負預測。

資料集（Dataset）

利用API的方式，使用 [中華職業棒球大聯盟](#)之數據

網絡說明

三層網絡架構圖



網路架構（Neural Network Architecture）

- 使用PyTorch框架創建一個帶有3層全連接網絡模型
- 隱藏層使用 Mish 非線性激活函數
- 輸出層搭配 CrossEntropyLoss 進行二元分類
- 損失函數:交叉熵(CrossEntropyLoss)
- 最佳化器(Optimizer)：Adam()
- 學習率衰減：ReduceLROnPlateau

資料切分

資料依時間順序切分為：

Dataset	筆數
Train	260
Valid	26
Valid2	52
Test	17

其中 Test 資料未參與模型訓練。

在 BPN 模型訓練階段，進一步於 Train 資料中採用 TimeSeriesSplit(n_splits=4) 進行時序交叉驗證，以避免未來資訊洩漏至過去資料。


Optuna 架構設定

1. 設定每個超參數搜尋範圍

超參數	說明	搜尋範圍
dropout1	第一層 Dropout 丟棄率	0 ~ 0.5
dropout2	第二層 Dropout 丟棄率	0 ~ 0.5
learning_rate	學習率	1e-5 ~ 1e-2
epochs	訓練循環次數	50 ~ 150
unit1	第一隱藏層神經元數	4 ~ 64
unit2	第二隱藏層神經元數	4 ~ 64

2. 本研究採用 Optuna 多目標最佳化（Multi-objective Optimization），同時最小化驗證集損失函數（Loss）並最大化驗證集準確率（Accuracy）。
3. Trial 次數設定
- 目前實驗將 n_trials 設定為：
- n_trials = 100，設定為 100，以避免在小型資料集上進行過多 trial 而造成驗證集過擬合。

架構



輸出結果

Optuna 最佳超參數

參數	數值
unit1	29
unit2	43
dropout1	0.2744
dropout2	0.3576
learning_rate	0.00603
epochs	105

最佳驗證結果：

- Valid Loss：0.7006
- Valid Accuracy：55.05%

BPN模型與其他模型

Model	Test Accuracy
Logistic Regression	0.588
Random Forest	0.471
XGBoost	0.588
BPN	0.706

結論

本研究比較 Logistic Regression、Random Forest、XGBoost 與 BPN 四種模型。

在相同資料集與特徵條件下，BPN 模型於測試集取得最高準確率 70.6%，顯示神經網路模型能有效學習投打數據與比賽結果間的非線性關係，具有較佳的預測能力。

貢獻

1. 以爬蟲方式，取得中華職棒網頁中的數據資料
2. 考量數據中含有時間資訊
3. 透過Python中Pytorch框架建立模型(非使用統計軟體)